Modélisation de l' Entrepôt de Données (Data Warehouse)

Dr.Dalel Kanzari

Table des matières

Introduction 3

I - **Architecture fonctionnelle** 4

II - **Modélisation Multidimensionnelle** 6

III - **La modélisation en étoile** 8

IV - **La modélisation en flocon** 10

V - **La modélisation en constellation** 11

VI - **Méthodes de conception d'un schéma multidimensionnel** 12

1. Méthodes descendantes (Top-down) [Inmon] 12

2. Botton-Up (approche inverse) 12

3. Middle-Out (approche hybride) 13

Conclusion 14

Contenus annexes 15

Introduction

L'Entrepôt de Données (ED) ou Data Warehouse (DW) fournit un stockage permanent des données des sources hétérogènes pour une exploitation future.

Base de Données utilisée à des fins d'*analyse* et de *prise de décision*

=> Questions typiques :

Quels sont les produits qui se vendent le mieux dans chaque site?

Quel est l'impact des données démographiques sur les résultats

de vente ?

- etc.

ED versus Bases de données opérationnelles

Critères	BD Opérationnelle	Entrepôt de Données
Objectif	Collecte de données	Consultation, analyse et prise de décision
Utilisateurs	Un département (employé)	Transversale (gestionnaire)
Types de données	Données de gestion (données courantes)	Données d'analyse (données historiques)
Informations	Détaillées	Détaillées & agrégées
Nombre d'accès	Dizaines	Millions
Opérations	Requêtes simples & prédéterminées	Requêtes complexes, ad-hoc

Architecture fonctionnelle

I

L'architecture de l'entrepôt comprend trois niveaux :

- Accès aux données sources
- Traitement des données
- Visualisation des données

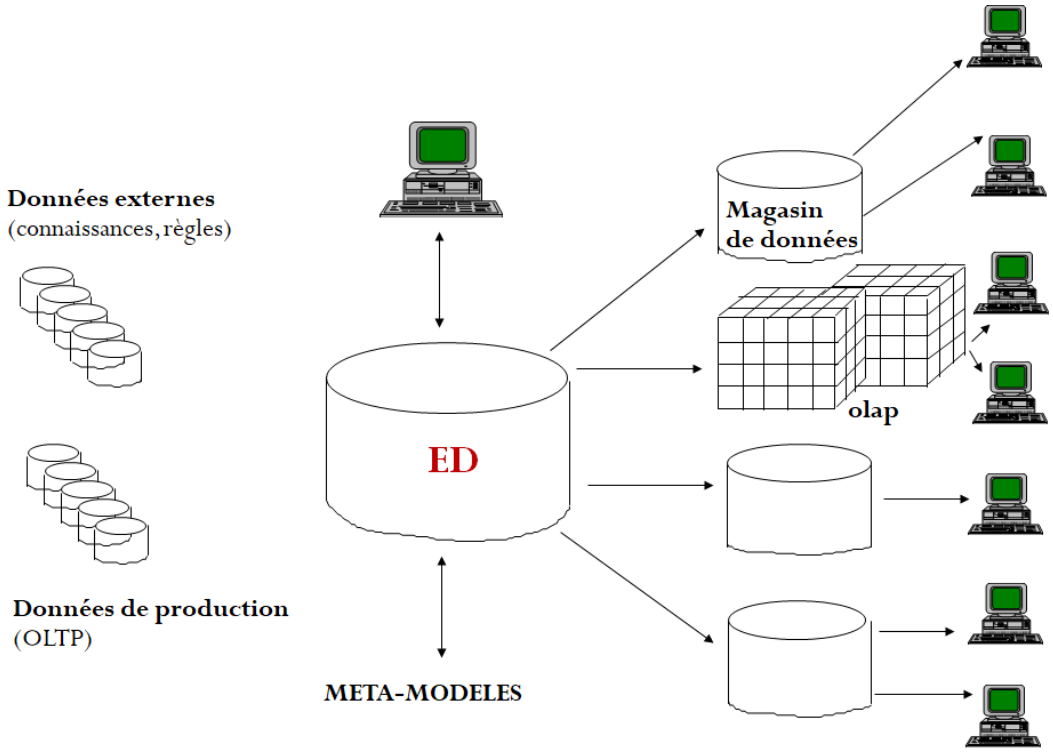

Magasin de données (datamart)

- Une vue partielle de l' ED orientée métier.
- Un sous-ensemble de l'ED contenant des informations relatives à un secteur d'activité (ou un métier) de l'entreprise.
- Plusieurs datamarts peuvent être créés selon les différents besoins des utilisateurs.
- destinés à un groupe de décideurs ou à un usage particulier.

Olap(Online Analytical Processing)

- OLAP permet l'analyse rapide multidimensionnelle sur des volumes de données importants.
- Il est alimenté par DW ou DM ou tout autre magasin de données centralisé et unifié
- *Objectifs*: génération des rapports (reporting) et analyse des données

Les Métadonnées

- Les métadonnées désignent les "données sur les données".
- Elles jouent un rôle central dans l'alimentation de l'entrepôt.
- Elles sont utilisées lors de l'extraction, l'agrégation, la transformation, le filtrage et le transfert des donnée
- Le méta-modèle constitue le référentiel unique:
    - utilisateurs, profils et droits
    - applications
    - modèles de données, structure des données
    - règles d'agrégation et de calcul

Structure des données

Un ED contient 5 types de données :

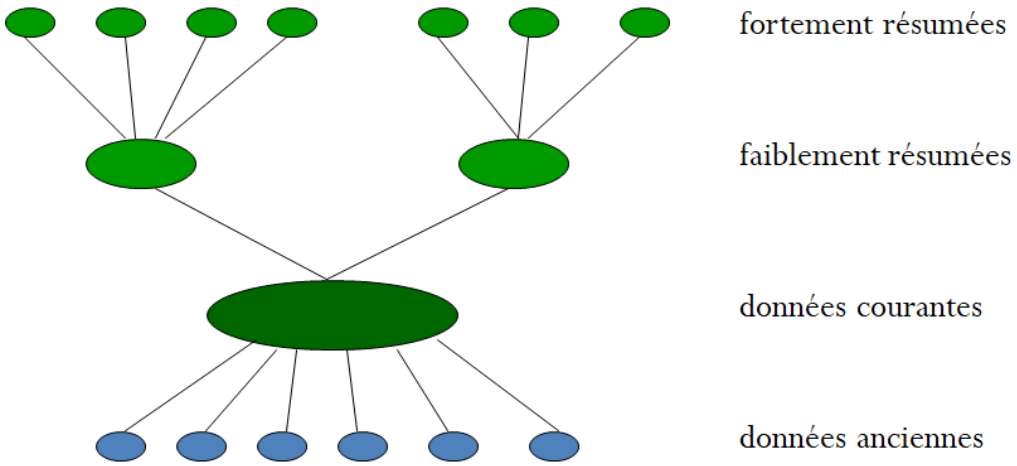

Modélisation Multidimensionnelle

II

Présentation des données comme des points dans un espace à plusieurs dimensions.

Ces points désignent les centres d'intérêts décisionnels (sujets) analysés en fonction des différents axes d'analyse.

Les schémas multidimensionnels:

- Le schéma en étoile
- Le schéma en flocon
- Le schéma en constellation

Schéma, fait , Dimensions

Schéma:

- Modélise des relations entre un (des) Fait(s) et des dimensions

- Exemple:

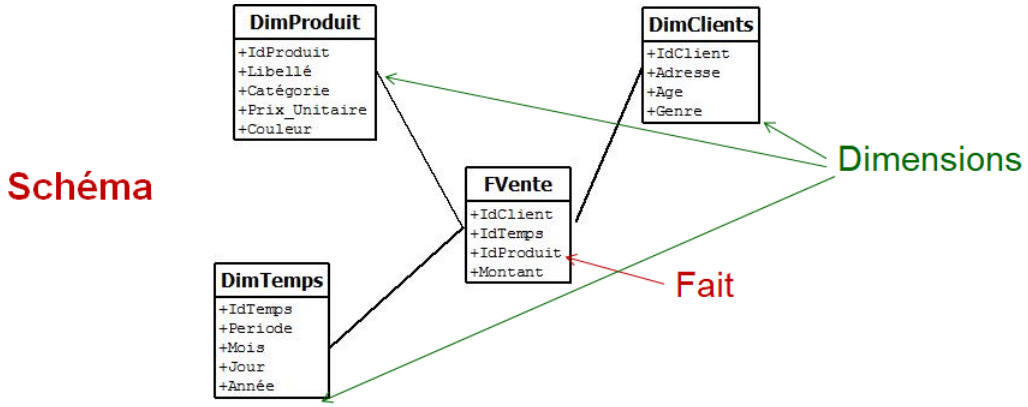

Dimension:

- Axe d'analyse permettant de visualiser les mesures d'activité d'un sujet d'analyse.

- Les attributs (ou paramètres) d'une dimension peuvent être organisés en hiérarchies, de la granularité la plus fine à la plus générale.

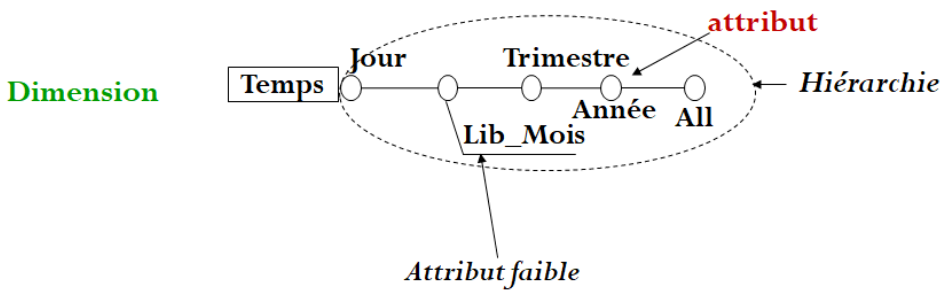

fait:

- Sujet de l'analyse (sur quoi porte l'analyse)

- Table contenant des informations opérationnelles de l'entreprise.

- Ces informations représentent les *mesures* d'activité.

- Une mesure est un indicateur d'analyse de type numérique et cumulable.

- Une mesure est accompagnée d'un ensemble de fonctions d'agrégation qui permettent de l'agréger en fonction des axes d'analyse.

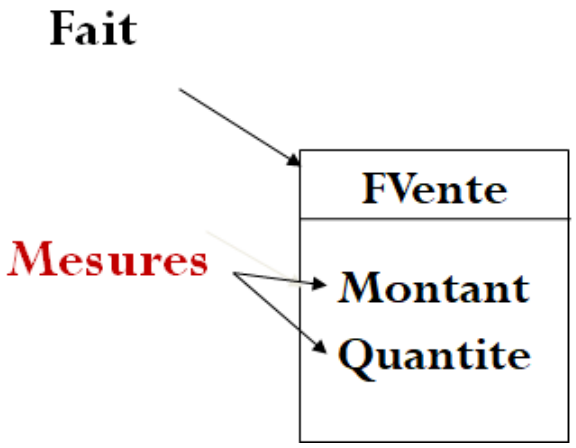

Propriétés des mesures :

- Additivité : somme sur toutes les mesures

Exemple : Montant; Quantité,etc.

- Semi-additivité : somme sur certaine dimensions

Exemple : nbr_contacts_clients, Etats_stocks, etc.

- Non-additivité : pas de somme , recalculer

Exemple : Max_CA, Min_CA, encours_moyen,etc.

La modélisation en étoile

III

Un sujet d'analyse (Fait):

- Comporte un ou plusieurs indicateurs (mesures) .
- Contient deux types de colonnes: métriques+ clés étrangères (navigation vers les tables de dimension)
- Contient typiquement un très grand nombre de lignes

n axes d'analyse (Dimensions):

- comportent les descripteurs des dimensions (paramètres).
- m perspectives d'analyse (Hiérarchies) organisant les paramètres en différentes granularités.
- Les dimensions n'ont pas de liaison entre elles
- Les attributs Doivent être:
- descriptifs (ex: chaînes de caractères);
- cohérentes(ex: pas de valeur manquante/obsolète/erronée/etc)
- de valeurs discrètes (ex: jour, âge)
- Rôles des attributs: filtrer/agréger les données, étiqueter les résultats, etc.

Exemple

« Modélisation des ventes en fonction du Temps, des produits et des sites de ventes »

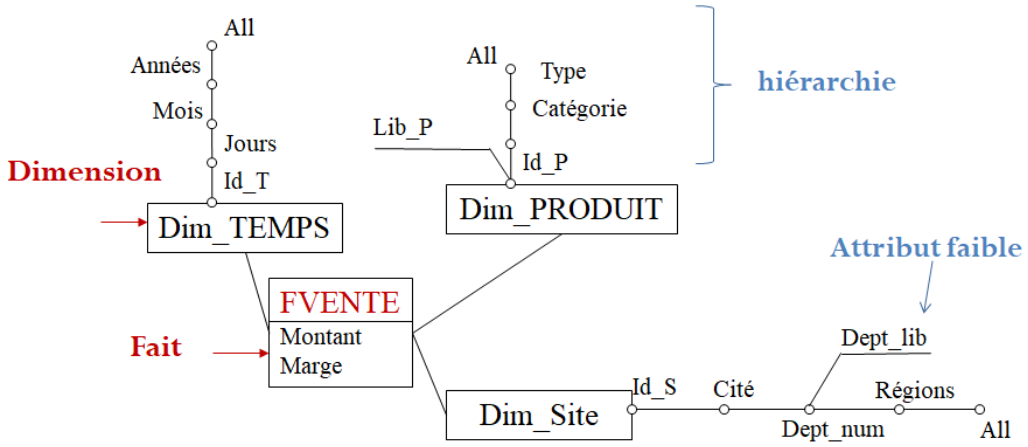

Exercice:

Une entreprise commerciale de vente de matériels informatique à plusieurs filiales internationales souhaite rassembler dans un Entrepôt de Données (ED) des informations sur les ventes du jour afin de dresser des tableaux de bord sur les chiffres d'affaires réalisés.

L'entreprise dispose d'un système d'information complexe, constitué des éléments suivants:

- des applications et bases de données éparses et hétérogènes sur les produits qu'elle vend,

- des applications et bases de données variées sur les clients,
- des Bases de données sur les personnels de l'entreprise,
- des Bases de données sur les filiales de l'entreprise.

Nous disposons des informations suivantes :

- Une vente correspond à un produit et un seul,
- Un produit est définit par: Refp, nom, description, type, famille.
- Une vente est effectuée par l'un des vendeurs du service de vente spécialisé dans le produit.
- Un client est défini par : RefC, nom, prénom, genre, adresse, catégorie.
- Un vendeur est défini par : RefV, nom, prénom, genre, adresse, filiale.

Questions :

- Proposer des indicateurs d'analyse pour ce système de gestion
- Proposer des axes d'analyse pour ce système.
- Proposer un schéma en étoile dimensionnel de l'ED.

La modélisation en flocon

IV

Modèle en étoile + embranchement des dimensions (Lorsque les dimensions sont trop volumineuses)

Avantages :

- réduction du volume,
- permettre des analyses détaillées (drill down) sur la dimension hiérarchisée.

Inconvénients :

- navigation difficile
- nombreuses jointures

Exemple

Normalisation de la dimension Produits

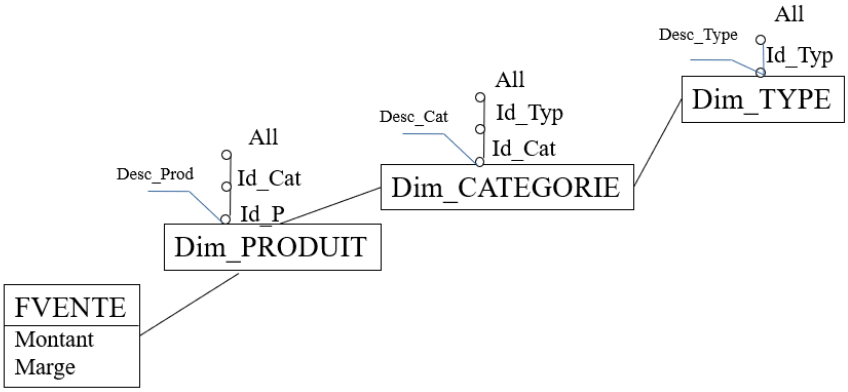

La modélisation en constellation

V

Série d'étoiles

- Fusion de plusieurs modèles en étoile qui utilisent des dimensions communes
- Plusieurs tables de fait et tables de dimensions, éventuellement communes
- n sujet d'analyse (Faits)
- n axes d'analyse (Dimensions) pouvant être , partagés entre les différents faits.

Avantages:

- Facilite les corrélation entre les différents sujets d'analyse
- Simplifie la modélisation avec la possibilité de partager les dimensions.

Exemple

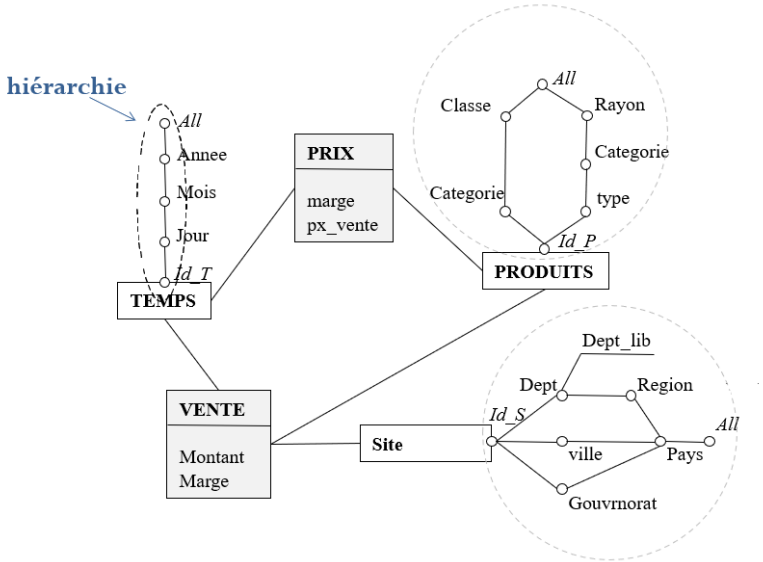

Méthodes de conception d'un schéma multidimensionnel

VI

1. *Méthodes descendantes (Top-down) [Inmon]*
2. *Méthodes ascendantes (Bottom-up) [Kimball]*
3. *Méthodes mixtes*

1. Méthodes descendantes (Top-down) [Inmon]

- Concevoir l'entrepôt d'une manière intégrale
- Connaître à l'avance toutes les dimensions et tous les faits.
- Cette démarche se base sur trois étapes:
  - *Collecte des données (besoins utilisateurs): (cf. p.15)* questionnaires /ou requêtes analytiques
  - Exemple: Analyser le montant des locations en fonction des mois et des véhicules pour les véhicules de type s.
  - *Spécification des besoins: (cf. p.15)* création de la matrice des besoins (mesures, paramètres).
  - Formalisation des besoins: schéma conceptuel

Avantages :

- Offrir une architecture intégrée : méthode complète
- Réutilisation des données
- Pas de redondances
- Vision claire et conceptuelle des données de l'entreprise

Inconvénients :

- Méthode contraignante
- Nécessite du temps

2. Botton-Up (approche inverse)

Créer les Datamarts et les regrouper par des niveaux intermédiaires pour construire l'entrepôt.

=> Livrer une solution rapide répondant aux requêtes d'analyse

Avantages :

- Simple à réaliser,
- Résultats rapides

- Efficace à court terme

Inconvénients :

- Peu efficace à long terme
- Le volume de travail d'intégration pour obtenir un entrepôt de données
- Risque de redondances (car réalisations indépendantes).

3. Middle-Out (approche hybride)

Concevoir intégralement l'entrepôt de données puis créer des divisions plus petites et plus gérables

Avantages :

Prendre le meilleur des 2 approches

Développement d'un modèle de données d'entreprise de manière itérative

Développement d'une infrastructure lourde qu'en cas de nécessité

Inconvénients :

implique, parfois, des compromis de découpage

peut dupliquer des dimensions identiques selon des besoins

Exemple : Exemple 1:

Une société de location de véhicules (possédant plusieurs agences dans divers pays) envisage construire un entrepôt de données afin d'analyser les montants de ses locations.

Déterminer un fait ainsi que ses dimensions permettant de répondre aux requêtes suivantes:

- Trouver le total des montants des locations par semaine, mois,...pour chaque employé.
- Trouver le total des montants de location par semaine ,mois ,...pour chaque modèle de voiture.
- Trouver le total des montants des locations pour tous les employés pour une ville donnée, région et état.

Questions :

Proposer un schéma conceptuel en étoile puis en flocon à cet entrepôt

Exemple : Exemple 2

On considère un entrepôt de données permettant d'observer les ventes de produits d'une entreprise. Le schéma des tables est le suivant :

- CLIENT (id-client, région, ville, pays, département)
- PRODUIT (id-prod, catégorie, coût-unitaire, fournisseur, prix-unitaire, nom-prod)
- TEMPS (id-tps, mois, nom-mois, trimestre, année)
- VENTE (id-prod, id-tps, id-client, date-expédition, prix-de-vente, frais-de-livraison)

Questions

1. Indiquer quelles sont la (les) table(s) de fait et les tables de dimension de cet entrepôt.
2. Donner pour chaque dimension, sa (multi-) hiérarchie.
3. Donner la représentation du schéma en étoile de l'entrepôt.
4. On veut transformer ce schéma en schéma en flocon. Donner la nouvelle représentation de la table TEMPS

Conclusion

Nous avons exploré trois principaux modèles de conception : l'étoile, le flocon et la constellation:

- Le modèle en étoile est caractérisé par un schéma de fait central entouré de tables de dimensions.
- Le modèle en flocon étend le concept de l'étoile en normalisant davantage les dimensions.
- Le modèle en constellation combine plusieurs schémas en étoile ou en flocon pour modéliser des domaines complexes et interconnectés.

En ce qui concerne les méthodes de conception, nous avons examiné le Top Down, le Bottom Up et l'approche Mixte :

- Le Top Down présente une vue d'ensemble du système pour une cohérence globale de l'ensemble.
- Le Bottom Up modélise des détails spécifiques, offrant une compréhension approfondie des besoins opérationnels, mais peut parfois manquer de vision globale.
- L'approche Mixte combine ces deux méthodes pour tirer parti de leurs avantages respectifs.

En résumé, le choix du modèle de conception et de la méthode dépendra des besoins spécifiques de l'organisation, de la complexité des données et des objectifs à atteindre pour garantir un entrepôt de données fonctionnel, efficace et évolutif.

Contenus annexes

> Exemple de requêtes analytiques

- R1 : Analyser le montant des locations En fonction des mois et des véhicules Pour les véhicules de type s.
- R2 : Analyser le montant des locations En fonction des mois et des agences
- R3 : Analyser le montant des locations En fonction des villes des agences
- R4 : Analyser le chiffre d'affaire des employés En fonction des mois
- Pour l'année 2019.
- R5 : Analyser le nombre de locations En fonction des marques de véhicules Pour l'état de Floride.
- R6 : Analyser les montants des locations En fonction des véhicules
- Pour la marque Peugeot

→ *(cf. p.12)*

> Exemple de Matrice des besoins

Création de la matrice des besoins:

1. Définition des faits
2. Définition des dimensions
3. Définition des hiérarchies

Paramètres / Indicateur	Ville	Région	Etat	Année	Mois	Id_Emp	Id_Client	Immat	Type	Marque
Mt location	√	√	√	√	√		√	√	√	√
Nb jours	√	√	√	√	√		√	√	√	√
CA				√	√	√				